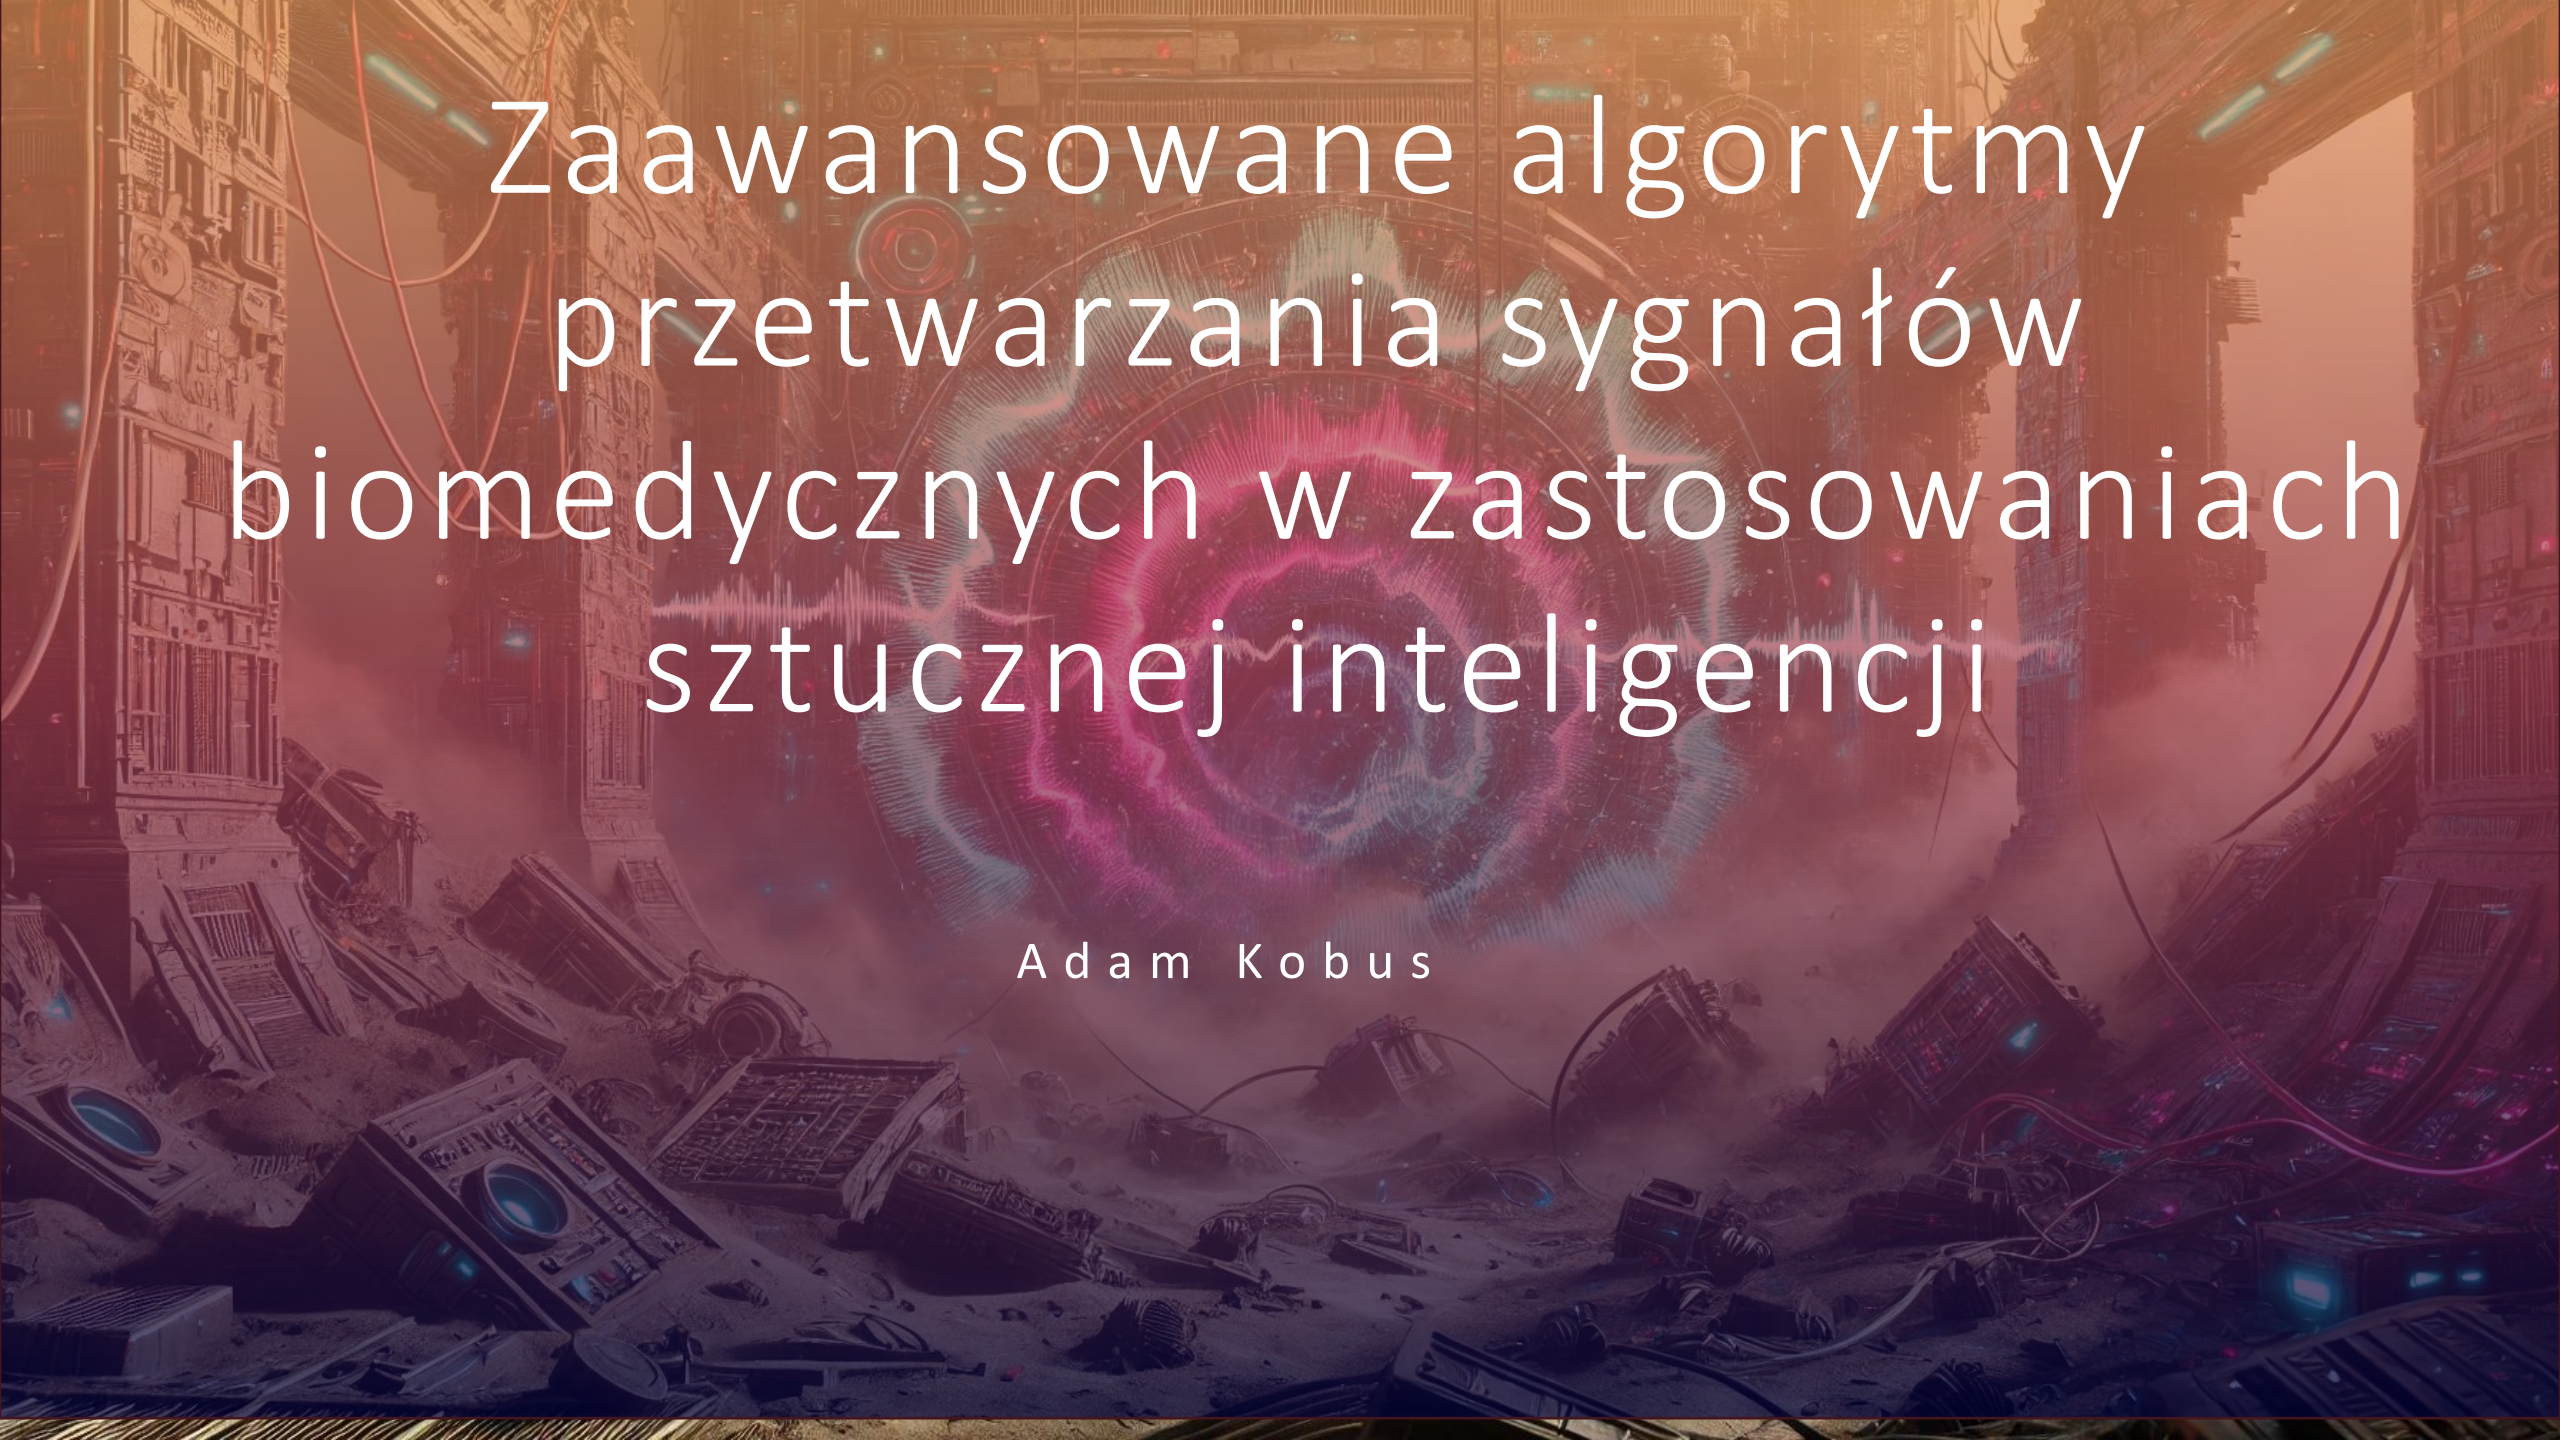




Zaawansowane algorytmy przetwarzania sygnałów biomedycznych w zastosowaniach sztucznej inteligencji

A d a m K o b u s



Low/high/band-pass filters – trzy artykuły

(2022) Instantaneous neural processing of communicative functions conveyed by speech prosody

(2020) Design and Implementation of Butterworth, Chebyshev-I and Elliptic Filter for Speech Signal Analysis

(2021) Speech Acoustic Modelling using Raw Source and Filter Components

Instantaneous neural processing of communicative functions conveyed by speech prosody

Rosario Tomasello ^{1,2,*}, Luigi Grisoni^{1,2}, Isabella Boux ^{1,3,4}, Daniela Sammler ^{5,6}, Friedemann Pulvermüller ^{1,2,3,4}

¹Brain Language Laboratory, Department of Philosophy and Humanities, Freie Universität Berlin, 14195 Berlin, Germany,

²Cluster of Excellence 'Matters of Activity. Image Space Material', Humboldt Universität zu Berlin, 10099 Berlin, Germany,

³Berlin School of Mind and Brain, Humboldt Universität zu Berlin, 10117 Berlin, Germany,

⁴Einstein Center for Neurosciences, 10117 Berlin, Germany,


⁵Research Group 'Neurocognition of Music and Language', Max Planck Institute for Empirical Aesthetics, 60322 Frankfurt am Main, Germany,

⁶Department of Neuropsychology, Max Planck Institute for Human Cognitive and Brain Sciences, 04103 Leipzig, Germany

*Address correspondence to Rosario Tomasello, Brain Language Laboratory, Department of Philosophy and Humanities, WE4, Freie Universität Berlin, Habelschwerdter Allee 45, 14195 Berlin, Germany. Email: Tomasello.R@fu-berlin.de

During conversations, speech prosody provides important clues about the speaker's communicative intentions. In many languages, a rising vocal pitch at the end of a sentence typically expresses a question function, whereas a falling pitch suggests a statement. Here, the neurophysiological basis of intonation and speech act understanding were investigated with high-density electroencephalography (EEG) to determine whether prosodic features are reflected at the neurophysiological level. Already approximately 100 ms after the sentence-final word differing in prosody, questions, and statements expressed with the same sentences led to different neurophysiological activity recorded in the event-related potential. Interestingly, low-pass filtered sentences and acoustically matched nonvocal musical signals failed to show any neurophysiological dissociations, thus suggesting that the physical intonation alone cannot explain this modulation. Our results show rapid neurophysiological indexes of prosodic communicative information processing that emerge only when pragmatic and lexico-semantic information are fully expressed. The early enhancement of question-related activity compared with statements was due to sources in the articulatory-motor region, which may reflect the richer action knowledge immanent to questions, namely the expectation of the partner action of answering the question. The present findings demonstrate a neurophysiological correlate of prosodic communicative information processing, which enables humans to rapidly detect and understand speaker intentions in linguistic interactions.

Key words: communicative functions; electroencephalography (EEG); pragmatics; prosody; sensorimotor system.



Opis ogólny


Artykuł przedstawia badanie nad neurofizjologiczną podstawą przetwarzania funkcji komunikacyjnych wyrażanych przez prozodię mowy (intonację/akcent/rytm/tempo/pauzy).

Celem badania było zbadanie, jak mózg przetwarza intonację wskazującą na różne funkcje komunikacyjne (pytania vs stwierdzenia) w zdaniach mówionych.

Wykorzystano EEG o wysokiej gęstości do rejestrowania aktywności mózgu podczas słuchania zdań włoskich różniących się intonacją końcową.

Już około 100 ms po końcowym słowie różniącym się prozodią, pytania i stwierdzenia wywoływały różną aktywność neurofizjologiczną. Efekt ten nie występował dla przefiltrowanych dolnoprzepustowo sygnałów mowy ani dla niemownych sygnałów muzycznych. Źródło różnicy zlokalizowano w regionie kory ruchowej związanym z artykulacją.

Wnioski: Wyniki demonstrowają neurofizjologiczny korelat przetwarzania prozodycznej informacji komunikacyjnej, który umożliwia ludziom szybkie wykrywanie i rozumienie intencji mówcy w interakcjach językowych.



Kontekst

Autorzy odnoszą się do badań w tym temacie:

1. Badania nad rozwojem językowym niemowląt (np. Dore 1975; Prieto et al. 2012; Frota et al. 2014) - pokazujące, że już na wczesnych etapach rozwoju dzieci wykorzystują intonację do wyrażania intencji komunikacyjnych.

2. Badania międzykulturowe (np. Chien et al. 2020; Gussenhoven and Chen 2000; Ohala 1994) - wykazujące, że słuchacze potrafią rozpoznać pytanie po rosnącej intonacji nawet w nieznanym im językach.




Kontekst

Autorzy odnoszą się do badań w tym temacie:

3. Badania EEG/ERP nad przetwarzaniem aktów mowy (np. Egorova et al. 2013, 2014, 2016; Van Ackeren et al. 2016; Tomasello, Kim, et al. 2019) - pokazujące szybkie (około 150 ms) pojawianie się różnic neurofizjologicznych między różnymi aktami mowy (np. prośby vs nazywanie).

4. Badania nad aktywacją kory ruchowej podczas przetwarzania próśb (Egorova et al. 2016; Van Ackeren et al. 2016; Tomasello, Kim, et al. 2019; Boux et al. 2021) - wykazujące aktywację obszarów kontrolujących ruchy rąk podczas rozumienia próśb o podanie przedmiotów.




Dane (korpus)

1. Korpus obejmował 110 nagrań w języku włoskim (native). Każde zdanie zostało nagrane w dwóch wersjach: z intonacją opadającą (stwierdzenie) i rosnącą (pytanie).

2. Przefiltrowane sygnały mowy:

- Te same 110 zdań poddane filtracji dolnoprzepustowej (low-pass filter, 300 Hz), aby usunąć zrozumiałą treść, zachowując kontur intonacyjny (F0)

3. Dźwięki niewokalne: 110 dźwięków fortepianu naśladujących kontury intonacyjne oryginalnych zdań




Dane (korpus)

4. Dane EEG: zarejestrowane od 26 zdrowych, praworęcznych osób (średni wiek 26 lat, zbalansowane wg płci). Wykorzystano 64 aktywne elektrody.

5. Dane behawioralne:

- Oceny uczestników dotyczące klasyfikacji usłyszanych bodźców jako pytania, stwierdzenia itp.
 - Wyniki zadania detekcji zmian głośności podczas eksperymentu EEG
- Łącznie wykorzystano 330 bodźców dźwiękowych (110 w każdym z 3 warunków) oraz dane EEG i behawioralne od uczestników badania.



Dane (preprocessing)

- Długość każdego zdania ustalono na 3,5 sekundy.
- Dodano zmienną ciszę trwającą 700-1000 ms przed rodzajnikiem (la, l', le, etc.).
- Wszystkie zdania znormalizowano do tej samej średniej energii dźwięku.
- Usunięto szum tła za pomocą oprogramowania Audacity 2.2.2.
- Zastosowano filtr dolnoprzepustowy (LPF) 300 Hz do każdego zdania.
- Stworzono niewokalne dźwięki muzyczne naśladujące kontury intonacyjne oryginalnych zdań.




A


spoken sentence (communicative action)

FALLING pitch


RISING pitch




low-pass filtered signal



non-vocal musical sound





Charakterystyki

1. Analiza akustyczna:

- Wyodrębniono średnią częstotliwość podstawową (Hz, pitch F0) i średnią intensywność (dB, RMS) końcowych słów we wszystkich zdaniach i odpowiadających im bodźcach kontrolnych.

- Analizę przeprowadzono dla najkrótszego wspólnego czasu trwania (680 ms).

- Rosnąca intonacja (rising pitch) - sygnalizująca pytanie i opadająca intonacja (falling pitch) - sygnalizująca stwierdzenie


2. Analiza EEG:

- Amplituda i topografia potencjałów wywołanych (ERP)

- Czas reakcji mózgu - wczesne odpowiedzi mózgu (około 100 ms po początku ostatniego słowa)

- Lokalizacja aktywności mózgu - aktywacja w lewej półkuli mózgu, szczególnie w regionach motorycznych związanych z artykulacją

- Źródła aktywności mózgu zrekonstruowane za pomocą Multiple Sparse Prior (MSP) i voxel-wise paired t-tests



Klasyfikacja

Nie używano żadnego klasyfikatora w sensie uczenia maszynowego.

- Wykorzystano analizę RMS (Root Mean Square) w celu określenia ogólnego potencjału mózgu w czasie.
- Zidentyfikowano dwa okna czasowe (0-48 ms i 68-118 ms po pojawieniu się rzeczownika) na podstawie szczytów RMS.
- Analiza statystyczna (ANOVA) była używana do porównania odpowiedzi mózgu na bodźce z rosnącą i opadającą intonacją w różnych warunkach (zdania, LPF, dźwięki muzyczne).
- Źródła aktywności mózgu zlokalizowano za pomocą analizy źródeł (Multiple Sparse Prior - MSP).



Metryki

1. Dane Akustyczne: Średnia częstotliwość podstawowa (F_0) w Hz, średnia intensywność (RMS) w dB

2. Odpowiedzi uczestników: Procentowe wyniki kategoryzacji bodźców (pytanie, stwierdzenie, nic, niejasne)

3. Dane EEG: Amplituda potencjałów wywołanych (ERP) w μV , latencja szczytowa (peak latency) w ms, root Mean Square (RMS) w μV

4. Analiza Źródeł: Współrzędne MNI (x, y, z), wartości t (t-values), liczba voxeli, wartości P (p-values), zarówno nieskorygowane, jak i skorygowane FWE (Family-Wise Error), obszary Brodmanna (Brodmann areas)




Wyniki

1. Wczesne różnice w aktywności mózgu: Już około 100 ms po pojawieniu się ostatniego słowa w zdaniu, zdania pytające i oznajmujące wywoływały różne wzorce aktywności neurofizjologicznej. To sugeruje bardzo szybkie przetwarzanie informacji prozodycznych związanych z funkcją komunikacyjną zdania.

2. Specyficzność dla mowy: Różnice w aktywności mózgu zaobserwowano tylko dla pełnych zdań mówionych. Sygnały mowy przefiltrowane dolnoprzepustowo (LPF) oraz dźwięki muzyczne, które naśladowały kontury intonacyjne, nie wywoływały tych różnic. Oznacza to, że sama intonacja (wysokość dźwięku) nie wystarcza do wywołania tych efektów – konieczna jest obecność treści leksykalno-semantycznych.


3. Lokalizacja źródła różnic: Analiza źródeł aktywności mózgu ujawniła, że różnice między pytaniami i stwierdzeniami pochodzą z lewej kory ruchowej, a konkretnie z obszarów związanych z artykulacją.



Czego brakuje?

- LPF – Low-pass filter
- Multiple Sparse Prior (MSP)
- Voxel-wise paired t-tests
- Peak latency
- ANOVA
- Family-Wise Error
- Obszary Brodmanna
- Normalizacja, Przeskalowanie
- Odszumianie
- SVM


Low-pass filter



Filtr dolnoprzepustowy (ang. low-pass filter, LPF) to układ lub algorytm, który przepuszcza sygnały o częstotliwościach niższych od określonej częstotliwości granicznej (f_c), jednocześnie tłumiąc sygnały o wyższych częstotliwościach.


Tutaj mamy kilka takich okien, w których wygaszanie częstotliwości odbywa się w różnym czasie.

Low-pass filter



Filtr dolnoprzepustowy (ang. low-pass filter, LPF) to układ lub algorytm, który przepuszcza sygnały o częstotliwościach niższych od określonej częstotliwości granicznej (f_c), jednocześnie tłumiąc sygnały o wyższych częstotliwościach.

Tutaj mamy kilka takich okien, w których wygaszanie częstotliwości odbywa się w różnym czasie.



Low-pass filter

$$P_{\omega} = \begin{cases} 1, & |\omega| \leq \Omega; \\ 0, & |\omega| > \Omega. \end{cases}$$


- T o p h a t – idealny filtr prostokątny

$$P_{\omega} = \exp -\omega^2 / \sigma^2$$

- G a u s s o w s k i

$$P_{\omega} = \frac{1}{1 + \frac{\omega^{2n}}{\Omega^{2n}}} \quad n = 1, 2, \dots$$


- B u t t e r w o r t h



Low-pass filter

Filtr ten dotyczy widma czasowo-częstotliwościowego. Aby uzyskać dla ramki takie widmo należy zastosować jeden z algorytmów, np. DFT/FFT lub rekonstrukcję widma na podstawie współczynników LPC.

FFT




Rysunek 1: Sygnał poliharmoniczny $0.3 \sin(2\pi 200x) + 0.7 \sin(2\pi 300x)$

Zatem każdy sygnał można zapisać w postaci:

$$x(t) = a_0/2 + a_1 \cos \omega_0 t + b_1 \sin \omega_0 t + a_2 \cos 2\omega_0 t + b_2 \sin 2\omega_0 t + \dots = \sum_{n=0}^{\infty} (a_n \cos n\omega_0 t + b_n \sin n\omega_0 t),$$

FFT



Rysunek 3: Równanie Eulera i jego graficzna reprezentacja

$$X(k) = \sum_{n=0}^{N-1} x(n) \left(\cos(2\pi \frac{kn}{N}) - i \sin(2\pi \frac{kn}{N}) \right) = \sum_{n=0}^{N-1} x(n) e^{-i2\pi \frac{k}{N} \cdot n},$$

gdzie:

- N - ilość próbek w oknie
- k - k -ty prążek widma, $k = 0..N - 1$
- i - jednostka urojona

DFT przekształca dyskretny sygnał $x[n]$ o długości N w jego reprezentację częstotliwościową $X[k]$. FFT to jego szybka odmiana oparta o długość N będącą potęgą 2.




Filtr pasmowo-przepustowy

1. Sygnał mowy był filtrowany za pomocą filtru Butterwortha czwartego rzędu.

2. Zakres przepuszczanego pasma wynosił od 400 Hz do 4000 Hz.

3. Ten zakres częstotliwości został wybrany jako szacunkowa lokalizacja energii samogłoskowej w mowie





ANOVA

Analiza wariancji (ANOVA) to metoda statystyczna służąca do porównywania średnich wartości w więcej niż dwóch grupach jednocześnie.

Bada, czy zaobserwowane różnice między średnimi kilku grup są na tyle duże (względem wewnątrzgrupowej zmienności), że nie można ich wyjaśnić przypadkiem.



ANOVA

Jednoczynnikowa analiza wariacji (one-way ANOVA) – badanie wpływu **jednego czynnika** (zmiennej grupującej) na zmienną zależną






Dwuczynnikowa analiza wariacji (two-way ANOVA) – badanie wpływu **dwóch niezależnych czynników** jednocześnie




ANOVA

Parametry te obliczamy korzystając z następujących wzorów:

Źródło zmienności (Z)	v_z (liczba stopni swobody)	SS_z (suma kwadratów odchyleń)	$MS_z = \frac{SS_z}{v_z}$ (średni kwadrat odchyleń)	$F_z = \frac{MS_z}{MS_e}$ (statystyka testowa)	F_{v_z, v_e} (wartość krytyczna odczytana z tablic)
A	$a - 1$	$bk \sum_{i=1}^a (\bar{y}_{i..} - \bar{y})^2$	$\frac{SS_A}{a-1}$	$\frac{MS_A}{MS_e}$	F_{v_A, v_e}
B	$b - 1$	$ak \sum_{j=1}^b (\bar{y}_{.j.} - \bar{y})^2$	$\frac{SS_B}{b-1}$	$\frac{MS_B}{MS_e}$	F_{v_B, v_e}
AB (interakcja)	$(a - 1)(b - 1)$	$k \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y})^2$	$\frac{SS_{AB}}{(a-1)(b-1)}$	$\frac{MS_{AB}}{MS_e}$	F_{v_{AB}, v_e}
Błąd (e)	$n - ab$	$\sum_{i=1}^a \sum_{j=1}^b \sum_{l=1}^k (y_{ijl} - \bar{y}_{ij.})^2$	$\frac{SS_e}{n-ab}$		
Całość	$n - 1$				



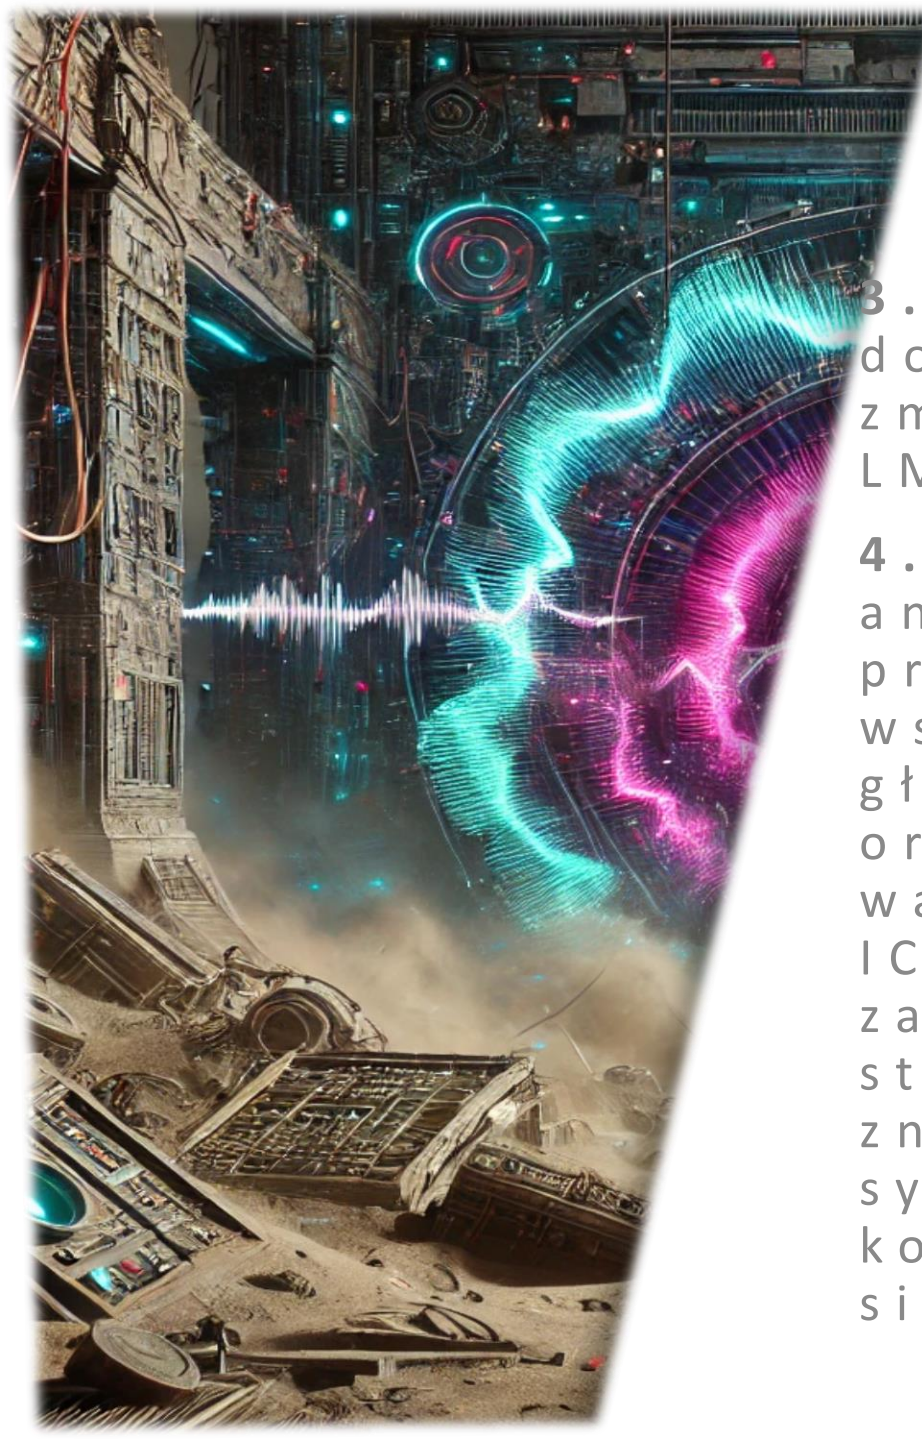


Odszumianie

Sygnały biomedyczne takie jak EEG (elektroencefalogram), EKG (elektrokardiogram) i EMG (elektromiogram) często zawierają **szumy i artefakty**, które utrudniają ich analizę diagnostyczną.

Metody odszumiania sygnałów biomedycznych:


1. Filtry dolno-, górno-, pasmowo-przepustowe, a także zaporowe wycinające konkretną częstotliwość, np. 50/60Hz sieci energetycznej (można usuwać np. pow. 45Hz przy sygnale EEG, ze względu na to, że fale mózgowe mają niższe częstotliwości)
2. Transformacja falkowa - rozbicie sygnału na składowe falkowe o różnej skali (częstotliwości) i lokalizacji w czasie i odszumianie poszczególnych składowych. Szczególnie cenna i znacząca w odszumianiu EEG.



Odszumianie

3. Filtracja adaptacyjna – dynamicznie dostosowuje swoje parametry do zmieniających się warunków: algorytm LMS, filtr Wienera,

4. Analiza składowych głównych (PCA) oraz analiza niezależnych składowych (ICA). PCA przekształca zbiór sygnałów na nowy układ współrzędnych, w którym kolejne składowe główne są liniowymi kombinacjami oryginalnych sygnałów, maksymalizującymi wariancję i wzajemnie nie skorelowanym. ICA - metoda separacji ślepej sygnałów, zakładająca, że źródła sygnału są statystycznie niezależne. Dąży do znalezienia takich kombinacji liniowych sygnałów, które dają wzajemnie niezależne komponenty. ICA bardzo dobrze sprawdza się dla EEG.





SVM

Support Vector Machines (SVM) to metoda uczenia maszynowego stosowana głównie w klasyfikacji i regresji. Kluczowym elementem działania SVM są **wektory nośne (support vectors)** – punkty danych, które mają największe znaczenie w wyznaczaniu granicy decyzyjnej.



SVM






SVM

Wektory nośne


1. **Definiują granicę decyzyjną** – zamiast używać wszystkich punktów w zbiorze treningowym, SVM wykorzystuje tylko te, które znajdują się najbliżej granicy. To sprawia, że metoda jest bardziej odporna na szum i niepotrzebne dane.
2. **Maksymalizują margines** – klasyfikator SVM stara się znaleźć taką granicę, aby maksymalnie oddalić ją od wektorów nośnych.
3. **Są kluczowe dla modelu** – jeśli usuniemy wektor nośny, granica decyzyjna może się zmienić. Natomiast usunięcie punktów, które nie są wektorami nośnymi, nie wpływa na model.

SVM


SVC with linear kernel




LinearSVC (linear kernel)



SVC with RBF kernel



SVC with polynomial (degree 3) kernel





Jupyter Notebook

Zadania wykonywać będziemy przy
użyciu Jupyter Notebook.





Źródła

<https://www.analog.com/en/resources/glossary/low-pass-filter.html>

<https://www.sciencedirect.com/topics/engineering/lowpass-filter>

<https://www.statystyka.eu/2-czynnikowa-analiza-wariancji-anova-uklad-czynnikowy.php#:~:text=Je%C5%9Bli%20w%20ka%C5%BCdej%20podgrupie%20utworzonej,cech%20na%20zmienn%C5%9B%C4%87%20cechy%20mierza%20linej>

<https://www.analyticsvidhya.com/blog/2018/01/anova-analysis-of-variance/>